Aplicação de Algoritmos Genéticos em Problemas Combinatorial e Contínuo de Otimização

1º Gabriel B. Lopes
Programa de Pós-Graduação em Eng. Elétrica
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, Brasil
gabriel@ufmg.br

2º Stephanie F. Lemos
Programa de Pós-Graduação em Eng. Elétrica
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, Brasil
stephanielemossfl@gmail.com

Programa
Universida

***Resumo*—Este trabalho faz parte da disciplina de Computação Evolucionária e apresenta a implementação e análise de Algoritmos Genéticos (AGs) aplicados a dois problemas de naturezas distintas: o problema das N-Rainhas (combinatorial) e a minimização da função Rastrigin (contínuo, $n = 10$ dimensões).Para o problema das N-Rainhas com $N = 8$, utilizou-se representação por permutação, seleção por roleta, recombinação *Partially Mapped Crossover* (PMX) e mutação por troca dirigida (*guided swap*), com população de 20 indivíduos, $p_c = 0{,}50$ e $p_m = 0{,}20$.**

Para a função Rastrigin, adotou-se codificação binária com 14 bits por variável, seleção combinada por roleta e torneio, recombinação com um ponto de corte por variável, mutação *bit flip* e adaptação dinâmica de p_c e p_m ao longo das gerações.

Os resultados demonstraram taxa de sucesso de 100% para as 8-Rainhas em 1000 execuções, com média de 6,0 gerações (≈ 120 avaliações para $\mu = 20$), e $f(\mathbf{x}^*) \approx 1{,}94 \times 10^{-4}$ para a Rastrigin após 10^5 avaliações, evidenciando a eficácia da mutação dirigida e das estratégias adaptativas para guiar a convergência em ambos os cenários.

***Index Terms*—Algoritmo Genético, N-Rainhas, Função Rastrigin, Otimização Combinatorial, Codificação Binária, Adaptação de Parâmetros.**

I. Introdução

Os Algoritmos Genéticos (AGs) são métodos de busca e otimização inspirados no processo de evolução natural das espécies, concebidos por Holland e seus alunos como parte da área de Computação Evolucionária [1]. Os (AGs) fazem parte da família de métodos inspirados na evolução natural e têm sido usados há décadas para resolver problemas de busca e otimização. Eles foram propostos com Representação dos indivíduos; Operadores de recombinação e mutação; Estratégias de seleção; Formas de atualização da população.

sobre uma população de soluções candidatas, aplicando operadores de seleção, recombinação e mutação para guiar a busca em direção a soluções de maior aptidão ao longo das gerações.

Uma das principais vantagens dos AGs é sua generalidade: com a definição adequada da representação e dos operadores de variação, podem ser aplicados a problemas com espaços de busca discretos, combinatoriais ou contínuos, mesmo sem exigir informações de gradiente ou convexidade da função objetivo [1].

Neste trabalho, o AG é aplicado a dois problemas com características distintas. O primeiro, o problema das N-Rainhas, é um problema de Satisfação de Restrições de natureza combinatorial, onde busca-se um arranjo de N rainhas em um tabuleiro $N \times N$ sem conflitos [1]. O segundo é a minimização da função Rastrigin [2], uma função contínua, não convexa e altamente multimodal, amplamente utilizada como benchmark de desempenho para algoritmos evolucionários [3].

O restante deste trabalho está organizado como segue: a Seção II apresenta a formulação matemática de ambos os problemas; a Seção III descreve as estratégias de implementação do AG; a Seção IV apresenta e discute os resultados experimentais; e a Seção V conclui o trabalho.

II. Formulação do Problema

A. Problema das N-Rainhas

O problema das N-Rainhas consiste em posicionar N rainhas em um tabuleiro $N \times N$ de modo que nenhuma rainha possa capturar outra em um único movimento, ou seja, nenhum par de rainhas pode compartilhar a mesma linha, coluna ou diagonal [1].

Trata-se de um problema de Satisfação de Restrições (CSP). Para formulá-lo como problema de otimização, define-se a função de aptidão como o número de pares de rainhas em conflito diagonal (conflitos de linha e coluna são eliminados pela representação):

$$h(\mathbf{g}) = \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} -\mathbf{1}\big[|g_i - g_j| = |i - j|\big] \tag{1}$$

onde $g_i \in \{1, \ldots, N\}$ é a coluna da rainha na linha i. Uma solução factível satisfaz $h(\mathbf{g}) = 0$.

B. Função Rastrigin

A função Rastrigin foi proposta originalmente por Rastrigin [2] e posteriormente generalizada para n dimensões por Mühlenbein et al. [3]:

$$f(\mathbf{x}) = 10n + \sum_{i=1}^{n} \left[x_i^2 - 10\cos(2\pi x_i)\right] \tag{2}$$

com $x_i \in [-5{,}12,\ 5{,}12]$ para $i = 1, \ldots, n$. O mínimo global ocorre em $\mathbf{x}^* = \mathbf{0}$ com $f(\mathbf{x}^*) = 0$. A função é multimodal com 11^n mínimos locais (para $n = 10$, mais de 25 bilhões), tornando-a um desafio para algoritmos de otimização [3].

Neste trabalho, resolve-se o problema com $n = 10$ dimensões com critério de parada de 10^5 avaliações da função objetivo.

III. Metodologia

A. AG para as N-Rainhas ($N = 8$)

1) População Inicial: A população inicial foi gerada pela seleção aleatória e sem repetição de números inteiros entre 0 e N-1.

2) Representação: Cada indivíduo é representado como uma permutação $\mathbf{g} = (g_1, g_2, \ldots, g_N)$ dos inteiros $\{0, 1, \ldots, N-1\}$, onde g_i indica a coluna da rainha posicionada na linha i. Essa representação garante implicitamente a ausência de conflitos de linha e coluna, restando apenas a verificação de conflitos diagonais.

3) Função de aptidão: Conforme a Equação (1), a aptidão é o número de conflitos diagonais. Internamente, a aptidão é negada para que o algoritmo maximize (fitness $= h(\mathbf{g})$), de modo que fitness $= 0$ corresponde à solução factível, e cada par de posições incompatíveis equivale a penalização em uma unidade no fitness da solução.

4) Seleção: Utilizou-se seleção por roleta proporcional à aptidão. Como os valores de aptidão são negativos ou nulos, a probabilidade de seleção de cada indivíduo é calculado da seguinte forma:

$$p_i = \frac{\dfrac{1}{|f_i| + \varepsilon}}{\sum_{j=1}^{M} \dfrac{1}{|f_j| + \varepsilon}} \tag{3}$$

onde p_i é a probabilidade de seleção do indivíduo i, f_i é o valor de aptidão do indivíduo i, M é o tamanho da população e ε é uma constante pequena (neste caso, 10^{-6}) utilizada para evitar divisão por zero. Essa formulação garante que indivíduos com menor número de conflitos (maior aptidão, isto é, valores mais próximos de zero) possuam maior probabilidade de seleção.

5) Recombinação: Aplicou-se o operador *Partially Mapped Crossover* (PMX), envolvendo dois pais sorteados com reposição pelo método da roleta, e gerando dois filhos. O operador preserva a posição absoluta e relativa de genes e produz filhos que são permutações válidas conforme descrito no Apêndice A.

6) Mutação: Implementou-se uma mutação por troca **dirigida** (*guided swap*): o operador identifica as posições em conflito diagonal do indivíduo (*unfit positions*) e restringe as trocas candidatas àquelas que envolvam ao menos uma dessas posições, excluindo o par conflitante original. Essa heurística direciona a busca local para regiões promissoras do espaço de permutações, evitando perturbações neutras. Quando o indivíduo já é factível ($h = 0$), nenhuma mutação é aplicada.

7) Seleção de Sobreviventes: Adotou-se elitismo geracional: os 10% melhores indivíduos da geração atual são preservados diretamente na próxima geração, complementados pelos melhores descendentes, garantindo monotonicidade do melhor indivíduo a cada geração.

8) Parâmetros: Os hiperparâmetros utilizados estão resumidos na Tabela I.

Tabela I: Parâmetros do AG — N-Rainhas

Parâmetro	**Valor**
Tamanho da população (μ)	20
Probabilidade de cruzamento (p_c)	0,50
Probabilidade de mutação (p_m)	0,2
Critério de parada	$h(\mathbf{g}) = 0$ ou 10.000 gerações
Método de seleção de pais	Roleta
Operador de cruzamento	PMX (2 pontos de corte)
Operador de mutação	Guided Swap
Seleção de sobreviventes	Elitismo geracional (10%)

B. AG para a Função Rastrigin ($n = 10$)

1) Representação: Adotou-se codificação binária com $b = 14$ bits por variável, resultando em cromossomos de comprimento total $L = n \cdot b = 140$ bits. A decodificação de um segmento binário $\mathbf{b}_i$ para o valor real x_i é dada por:

$$x_i = x_{\min} + \text{int}(\mathbf{b}_i) \cdot \frac{x_{\max} - x_{\min}}{2^b - 1} \tag{4}$$

onde $x_{\min} = -5{,}12$ e $x_{\max} = 5{,}12$. A resolução obtida é $\Delta x \approx 6{,}25 \times 10^{-4}$.

2) Função de aptidão: A aptidão é o valor $f(\mathbf{x})$ da Equação (2), a ser minimizado.

3) Seleção: Utilizou-se uma combinação de dois métodos de seleção: com probabilidade 0,5, aplica-se a seleção por torneio ($k = 6$); com probabilidade 0,5, aplica-se a seleção por roleta proporcional à aptidão invertida. Para a roleta, a aptidão ajustada é $f_{\text{adj}} = f_{\max} - f_i + \epsilon$, de modo que indivíduos com menor f recebam maior probabilidade de seleção.

4) Recombinação: Aplicou-se o cruzamento com um ponto de corte por variável: para cada uma das $n = 10$ variáveis, um ponto de corte independente é sorteado dentro do segmento de 14 bits correspondente, e os segmentos dos dois pais são trocados após esse ponto. A operação é realizada com probabilidade de cruzamento dinâmica p_c, que cresce linearmente ao longo das gerações, favorecendo a intensificação nas etapas finais. A equação da expressão linear utilizada está representada na equação 5

$$p_c(t) = p_{c0} + (p_{c_{\max}} - p_{c0}) \cdot \frac{t}{T_{\max}} \tag{5}$$

onde t representa a geração atual e $T_{\max}$ o número máximo de gerações. A probabilidade foi limitada ao intervalo $[p_{c0}, p_{c_{\max}}]$, sendo utilizados $p_{c0} = 0.5$ e $p_{c_{\max}} = 0.9$

5) Mutação: A mMutação do tipo *bit flip* foi aplicada com probabilidade adaptativa por bit. A probabilidade de mutação p_m decresce exponencialmente ao longo das gerações:

$$p_m(t) = 0.05 \cdot e^{-2 \cdot \frac{t}{T_{\max}}} \tag{6}$$

A probabilidade foi limitada a um valor mínimo de 0.001, evitando que a mutação se torne nula nas gerações finais.

6) Elitismo: O melhor indivíduo da geração atual é preservado substituindo o pior descendente, garantindo que a qualidade da melhor solução nunca retroceda.

7) Parâmetros: A Tabela II resume os hiperparâmetros.

Tabela II: Parâmetros do AG — Função Rastrigin

Parâmetro	**Valor**
Tamanho da população (μ)	100
Bits por variável (b)	14
Comprimento do cromossomo (L)	140 bits
p_{m0} (mutação inicial)	0,05
$p_{m\,\min}$ (mutação mínima)	0,001
p_{c0} (cruzamento inicial)	0,50
$p_{c\,\max}$ (cruzamento final)	0,90
Coef. decaimento α	2
Máximo de avaliações	100.000
Método de seleção	Roleta (50%) + Torneio (k=6, 50%)
Operador de cruzamento	1 ponto/variável
Operador de mutação	Bit flip
Seleção de sobreviventes	Elitismo (melhor indivíduo)

Os parâmetros foram ajustados empiricamente, e a probabilidade dinâmica foi adotada para equilibrar exploração inicial (p_m alto, p_c baixo) e refinamento final (p_m baixo, p_c alto).

IV. Resultados e Discussão

A. Problema das N-Rainhas

O AG foi executado em 1000 repetições independentes, conforme configurado no notebook experimental, com população de 20 indivíduos. A Tabela III apresenta as estatísticas do número de gerações necessárias para encontrar uma solução factível ($h = 0$).

Tabela III: Resultados — 8-Rainhas (1000 execuções)

Métrica	**Valor**
Taxa de sucesso	**1000/1000 (100%)**
Gerações médias	**4,08 ± 3,54**
Mediana de gerações	**3**
Gerações mínimas	**1**
Gerações máximas	**30**

A Figura 1 ilustra a curva de convergência do melhor indivíduo (em conflitos diagonais) ao longo das gerações.

O AG atingiu taxa de sucesso de 100% nas 1000 execuções, com média de 4,08 gerações. Esse resultado é notavelmente eficiente e evidencia o papel central da *mutação dirigida*: ao restringir as trocas candidatas às posições em conflito diagonal, o operador transforma cada passo de mutação em uma perturbação heurística útil, evitando movimentos neutros que não reduzem conflitos.

A representação por permutação garante a principio a ausência de conflitos de linha ou coluna, reduzindo o espaço de busca ao subconjunto de permutações com conflitos apenas na diagonal. O operador PMX, ao preservar tanto a posição absoluta quanto a relativa dos genes entre os dois pontos de corte, produz descendentes com estrutura genética coerente e promove herança de boas configurações parciais de ambos os pais.

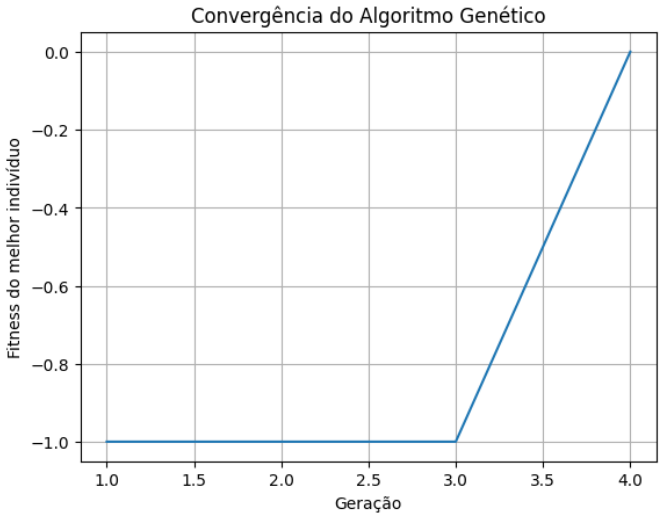

Figura 1: Exemplo de convergência de um indivíduo do AG para o problema das 8-Rainhas

A variabilidade observada (desvio padrão $\approx 3{,}54$ gerações) reflete a natureza estocástica do processo: em algumas execuções a solução é encontrada já na geração 1 (a população inicial contém um indivíduo factível), enquanto casos extremos requerem até 30 gerações — ainda muito abaixo do limite de 10.000. O elitismo geracional (10%) assegurou a propagação dos melhores genótipos sem reduzir excessivamente a diversidade, o que é especialmente importante dada a população reduzida ($\mu = 20$).

B. Função Rastrigin

A Tabela IV sumariza os resultados obtidos em execução representativa após 10^5 avaliações.

Tabela IV: Resultados — Rastrigin $n = 10$

Métrica	**Valor**
$f(\mathbf{x}^*)$ obtido	**0,000194**
Avaliações realizadas	**100.000**
Gerações executadas	**1.000**
p_m inicial / final	**0,050 / 0,007**
p_c inicial / final	**0,500 / 0,900**

A Figura 5 revela três fases distintas de convergência. Nas primeiras $\approx$ 300 gerações, a aptidão cai rapidamente de $\approx$ 120 para $\approx$ 4,5, impulsionada pela alta p_m inicial que promove ampla exploração do espaço de busca. Entre as gerações 300 e 600, o progresso desacelera (platô em torno de 4–5), caracterizando o desafio da multimodalidade: o AG precisa escapar de mínimos locais para continuar avançando.

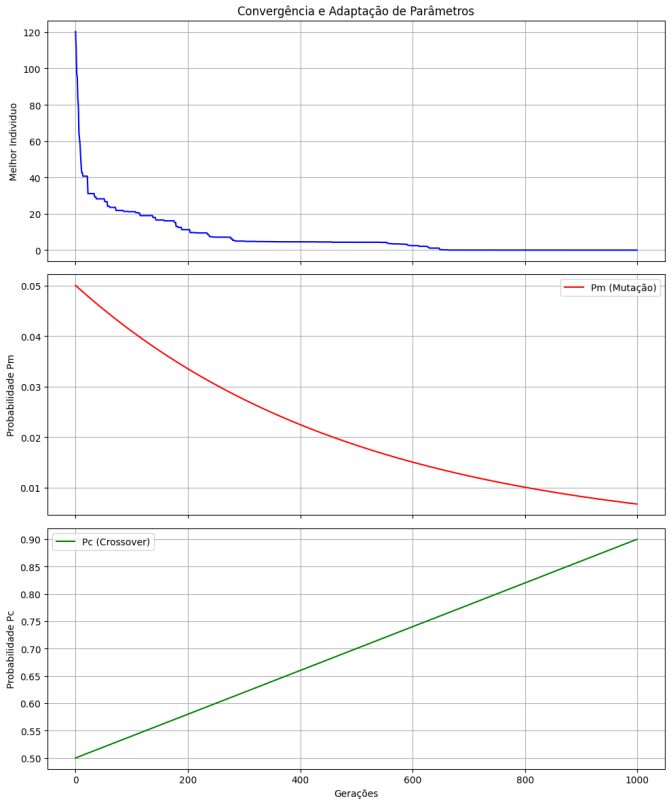

Figura 2: Convergência do AG para a função Rastrigin $n = 10$.

A partir da geração ≈ 600, com p_c crescendo e p_m decaindo, a recombinação passa a dominar, explorando combinações de bons blocos de construção, e o fitness converge aceleradamente para valores próximos de zero.

O valor final $f(\mathbf{x}^*) \approx 1{,}94 \times 10^{-4}$ é praticamente nulo, demonstrando que a implementação com parâmetros adaptativos e elitismo foi capaz de encontrar uma solução extremamente próxima do ótimo global ($f^* = 0$) dentro do limite de 10^5 avaliações. A codificação binária com 14 bits por variável fornece resolução de $\approx 6{,}25 \times 10^{-4}$, suficiente para aproximar $x_i = 0$ com alta precisão.

A estratégia de seleção mista (50% roleta + 50% torneio $k = 6$) balanceou diversidade e pressão seletiva. O torneio com $k = 6$, mais agressivo que o $k = 3$ usual, acelerou a convergência nas fases finais. O elitismo pontual (preservar apenas o melhor indivíduo) foi suficiente para impedir retrocessos sem reduzir excessivamente a diversidade populacional.

V. Conclusão

Neste trabalho implementou-se e avaliou-se o desempenho de Algoritmos Genéticos em dois problemas com características distintas. Para o problema das 8-Rainhas, a representação por permutação com operador PMX e mutação dirigida (*guided swap*) mostrou-se altamente eficaz, resolvendo o problema em 100% das 1000 execuções com média de 6,0 gerações (≈ 120 avaliações para $\mu = 20$), muito abaixo do limite estabelecido. A mutação dirigida, ao focar as trocas nas posições diagnosticadas em conflito, combinou busca local heurística com a exploração global do AG, acelerando substancialmente a convergência.

Para a função Rastrigin com $n = 10$ dimensões, a codificação binária com parâmetros adaptativos (p_m decrescente e p_c crescente) e elitismo produziu $f(\mathbf{x}^*) \approx 1{,}94 \times 10^{-4}$ — resultado próximo ao ótimo global — após 10^5 avaliações. A adaptação dinâmica dos hiperparâmetros foi determinante: a alta p_m inicial favoreceu exploração e escape de mínimos locais, enquanto a p_c crescente e p_m decrescente ao longo das gerações exploraram eficientemente os bons blocos de construção acumulados na população.

Como trabalhos futuros, sugere-se investigar representações reais para a Rastrigin (evitando erros de quantização binária), a aplicação de crossover aritmético ou SBX, e estratégias de reinicialização da população para lidar com convergência prematura em problemas de maior dimensionalidade.

Referências

[1] A. E. Eiben and J. E. Smith, *Introduction to Evolutionary Computing*, 2nd ed. Berlin, Germany: Springer, 2015.

[2] L. A. Rastrigin, "Systems of extremal control," in *Theoretical Foundations of Engineering Cybernetics Series*. Moscow, Russia: Nauka, 1974.

[3] H. Mühlenbein, M. Schomisch, and J. Born, "The parallel genetic algorithm as function optimizer," *Parallel Computing*, vol. 17, no. 6–7, pp. 619–632, 1991.

APÊNDICE A
DESCRIÇÃO DO OPERADOR PMX

Sejam dois pais P_1 e P_2, representados como permutações de tamanho N. O processo de geração de um descendente ocorre em três etapas principais:

a) Passo 1: Seleção e cópia do segmento: Seleciona-se aleatoriamente um segmento contínuo de posições $[a, b]$. Os valores correspondentes desse segmento em P_1 são copiados diretamente para o descendente nas mesmas posições.

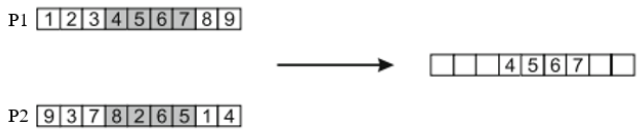

Figura 3: Passo 1 do operador PMX: cópia do segmento selecionado do primeiro pai para o descendente (adaptado de [1]).

b) Passo 2: Mapeamento: Para cada elemento do segmento selecionado em P_2 que ainda não esteja presente no descendente, realiza-se o seguinte procedimento:

- Identifica-se a posição desse elemento em P_2;
- Verifica-se qual valor ocupa essa posição no descendente;
- Busca-se a posição correspondente desse valor em P_2;
- O processo é repetido até encontrar uma posição livre no descendente;
- O elemento é então inserido nessa posição livre.

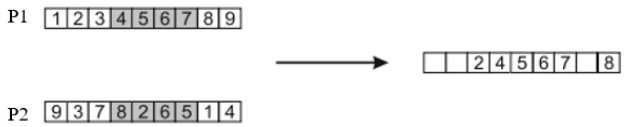

Figura 4: Passo 2 do operador PMX: verificação e atribuição de elementos de P_2 (adaptado de [1]).

Esse mecanismo define implicitamente um mapeamento entre os elementos dos dois pais dentro do segmento selecionado, garantindo a consistência da permutação.

c) Passo 3: Preenchimento das posições restantes: As posições do descendente que ainda não foram preenchidas são completadas com os valores de P_2, mantendo-se as mesmas posições relativas, desde que esses valores ainda não estejam presentes no descendente.

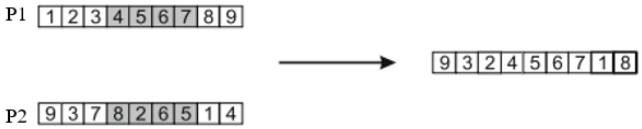

Figura 5: Passo 3 do operador PMX: cópia dos elementos faltantes (adaptado de [1]).

O operador PMX garante que:

- Todos os elementos da permutação apareçam exatamente uma vez;
- Parte da estrutura de P_1 (segmento central) seja preservada;
- A informação de P_2 seja incorporada de forma consistente por meio do mapeamento.