

Trabalho Prático 2: Evolução Diferencial, PSO e Algoritmo Genético

1º Gabriel B. Lopes

Programa de Pós-Graduação em Eng. Elétrica
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, Brasil
bonanato96@ufmg.br

3º Vanderley M. Silva

Programa de Pós-Graduação em Eng. Elétrica
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, Brasil
vanderleym@ufmg.br

2º Stephanie F. Lemos

Programa de Pós-Graduação em Eng. Elétrica
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, Brasil
stephaniesfl@ufmg.br

4º Vinicius F. Cerqueira

Programa de Pós-Graduação em Eng. Elétrica
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, Brasil
vinerreira@ufmg.br

Resumo—Este trabalho aplica três algoritmos evolucionários a dois problemas de otimização distintos. Para a minimização da função Rastrigin com $n = 10$ dimensões, implementam-se Evolução Diferencial (DE) na variante *current-to-best/1/bin* e Otimização por Enxame de Partículas (PSO) com inércia adaptativa linear. Para o Problema do Caixeiro Viajante (TSP) na instância *att48*, implementa-se um Algoritmo Genético (AG) com crossover PMX, mutação *Cross-Aware RSM* e seleção por torneio com elitismo. Os resultados mostram que o DE apresenta convergência robusta (taxa de sucesso 100%), enquanto o PSO demonstra maior variabilidade (taxa de sucesso 40%). Os resultados do AG para o TSP são apresentados e discutidos na seção de Resultados.

Index Terms—Evolução Diferencial, PSO, Algoritmo Genético, Função Rastrigin, Problema do Caixeiro Viajante

I. INTRODUÇÃO

Algoritmos evolucionários constituem uma família de métodos de otimização inspirados em mecanismos da evolução natural. Entre eles, a Evolução Diferencial (DE) [2] e a Otimização por Enxame de Partículas (PSO) [3] destacam-se pela eficácia em problemas de otimização contínua e multimodal. Já o Algoritmo Genético (AG) [4] é amplamente empregado em problemas combinatórios, como o Problema do Caixeiro Viajante (TSP) [6].

Neste trabalho, realizamos duas tarefas: (i) minimização da função Rastrigin com $n = 10$ variáveis via DE e PSO; e (ii) resolução do TSP na instância *att48* via AG. O critério de parada para a função Rastrigin é de 10^5 avaliações da função objetivo ou convergência abaixo de 10^{-3} . Para o TSP, o critério de parada é de 1000 gerações.

II. FORMULAÇÃO DOS PROBLEMAS

A. Função Rastrigin

A função Rastrigin é uma função contínua, não-convexa e multimodal, definida como [1]:

$$f(\mathbf{x}) = 10n + \sum_{i=1}^n [x_i^2 - 10 \cos(2\pi x_i)] \quad (1)$$

com $x_i \in [-5, 12, 5, 12]$ para $i = 1, \dots, n$. O mínimo global ocorre em $\mathbf{x}^* = \mathbf{0}$ com $f(\mathbf{x}^*) = 0$. Para este trabalho, utiliza-se $n = 10$.

O problema de otimização é:

$$\mathbf{x}^* = \arg \min_{\mathbf{x} \in [-5, 12, 5, 12]^{10}} f(\mathbf{x}) \quad (2)$$

B. Problema do Caixeiro Viajante (TSP)

O TSP consiste em determinar o ciclo hamiltoniano de distância mínima em um grafo completo $G = (V, E)$ com n cidades [6]. Definindo a variável binária:

$$x_{ij} = \begin{cases} 1, & \text{se o caixeiro vai de } i \text{ para } j \\ 0, & \text{caso contrário} \end{cases} \quad (3)$$

a formulação matemática é:

$$\min \sum_{i=1}^n \sum_{j>i} c_{ij} x_{ij} \quad (4)$$

sujeito a:

$$\sum_{j<i} x_{ji} + \sum_{j>i} x_{ij} = 2, \quad \forall i \in \{1, \dots, n\} \quad (5)$$

$$\sum_{i,j \in S} x_{ij} \leq |S| - 1, \quad \forall S \subset V \quad (6)$$

$$\mathbf{x} \in \mathbb{B}^{n(n-1)/2} \quad (7)$$

A restrição (5) garante que cada cidade possui exatamente uma cidade predecessora e uma sucessora. A restrição (6) elimina a formação de sub-rotas. Neste trabalho utiliza-se a instância *att48* da TSPLIB [7], composta por 48 cidades

(capitais dos EUA), com distância do tipo ATT (*pseudo-euclidiana*) e solução ótima conhecida de 10628.

A distância ATT entre cidades i e j é calculada como:

$$d_{ij} = \left\lceil \sqrt{\frac{(x_i - x_j)^2 + (y_i - y_j)^2}{10}} \right\rceil \quad (8)$$

III. METODOLOGIA

A. Evolução Diferencial para a Função Rastrigin

1) *Representação e Inicialização*: Cada indivíduo é representado como um vetor real $\mathbf{x} \in \mathbb{R}^{10}$. A população inicial de $N_p = 100$ indivíduos é amostrada uniformemente em $[-5, 12, 5, 12]^{10}$.

2) *Estratégia de Mutação*: Utiliza-se a variante **DE/current-to-best/1/bin**, em que o vetor mutante para o indivíduo i na geração g é:

$$\mathbf{v}_i^{(g)} = \mathbf{x}_i^{(g)} + \lambda (\mathbf{x}_{\text{best}}^{(g)} - \mathbf{x}_i^{(g)}) + F (\mathbf{x}_{r_1}^{(g)} - \mathbf{x}_{r_2}^{(g)}) \quad (9)$$

onde $r_1, r_2 \in \{1, \dots, N_p\} \setminus \{i\}$ são índices aleatórios distintos, $\mathbf{x}_{\text{best}}^{(g)}$ é o melhor indivíduo da geração g , F é o fator de escala diferencial e λ controla a intensidade de atração ao melhor. O vetor mutante é restrito ao domínio por *clipping*.

3) *Crossover Binomial*: O vetor de *trial* $\mathbf{u}_i^{(g)}$ é formado pelo cruzamento binomial entre $\mathbf{x}_i^{(g)}$ e $\mathbf{v}_i^{(g)}$:

$$u_{i,j}^{(g)} = \begin{cases} v_{i,j}^{(g)}, & \text{se } r_j \leq CR \text{ ou } j = j_{\text{rand}} \\ x_{i,j}^{(g)}, & \text{caso contrário} \end{cases} \quad (10)$$

onde $r_j \sim \mathcal{U}(0, 1)$ e $j_{\text{rand}} \in \{1, \dots, n\}$ garante ao menos uma componente do mutante.

4) *Seleção Gulosa*: A seleção é gulosa (*greedy*): o indivíduo de *trial* substitui o progenitor somente se apresentar fitness melhor ou igual:

$$\mathbf{x}_i^{(g+1)} = \begin{cases} \mathbf{u}_i^{(g)}, & \text{se } f(\mathbf{u}_i^{(g)}) \leq f(\mathbf{x}_i^{(g)}) \\ \mathbf{x}_i^{(g)}, & \text{caso contrário} \end{cases} \quad (11)$$

5) *Hiperparâmetros*: Os hiperparâmetros do DE são apresentados na Tabela I.

Tabela I
HIPERPARÂMETROS DO DE

Parâmetro	Símbolo	Valor
Tamanho da população	N_p	100
Fator de escala	F	0,8
Taxa de crossover	CR	0,5
Atração ao melhor	λ	0,9
Máx. de avaliações	—	10^5
Tolerância	ε	10^{-3}

B. PSO para a Função Rastrigin

1) *Representação e Inicialização*: Cada partícula i possui posição $\mathbf{x}_i \in \mathbb{R}^{10}$ e velocidade $\mathbf{v}_i \in \mathbb{R}^{10}$. As posições são inicializadas uniformemente em $[-5, 12, 5, 12]^{10}$ e as velocidades em $[-1, 1]^{10}$.

2) *Atualização de Velocidade e Posição*: A topologia *gbest* (melhor global) é adotada. A atualização de velocidade segue:

$$\mathbf{v}_i^{(t+1)} = \omega_t \mathbf{v}_i^{(t)} + c_1 \mathbf{r}_1 \odot (\mathbf{p}_i - \mathbf{x}_i^{(t)}) + c_2 \mathbf{r}_2 \odot (\mathbf{g} - \mathbf{x}_i^{(t)}) \quad (12)$$

e a posição é atualizada por $\mathbf{x}_i^{(t+1)} = \mathbf{x}_i^{(t)} + \mathbf{v}_i^{(t+1)}$, com *clipping* para manutenção dos limites, onde $\mathbf{p}_i$ é o melhor histórico da partícula i (*pbest*), $\mathbf{g}$ é o melhor global (*gbest*), e $\mathbf{r}_1, \mathbf{r}_2 \sim \mathcal{U}(0, 1)^{10}$ são vetores aleatórios independentes.

3) *Inércia Adaptativa*: A inércia ω_t decresce linearmente ao longo das avaliações:

$$\omega_t = \omega_{\max} - (\omega_{\max} - \omega_{\min}) \cdot \frac{e_t}{e_{\max}} \quad (13)$$

onde e_t é o número acumulado de avaliações e $e_{\max} = 10^5$.

4) *Hiperparâmetros*: Os hiperparâmetros do algoritmo PSO para o problema da função Rastrigin estão apresentados na Tabela II a seguir:

Tabela II
HIPERPARÂMETROS DO PSO

Parâmetro	Símbolo	Valor
Tamanho do enxame	N_p	100
Inércia máxima	$\omega_{\max}$	0,85
Inércia mínima	$\omega_{\min}$	0,50
Componente cognitiva	c_1	1,9
Componente social	c_2	1,75
Máx. de avaliações	—	10^5
Tolerância	ε	10^{-3}

C. Algoritmo Genético para o TSP

1) *Representação*: Cada indivíduo é representado como uma permutação dos $n = 47$ rótulos de cidade, denotada $\pi = (\pi_1, \pi_2, \dots, \pi_{47})$. Uma das 48 cidades (arbitrada como nó 0) não está incluída na representação, pois ela é fixada como ponto de origem e término do tour. O valor de *fitness* é o inverso do comprimento da rota (maximização interna), equivalente à minimização da distância percorrida. No fitness é considerada as distâncias referentes ao nó 0.

2) *Inicialização*: A população inicial de $N_p = 100$ indivíduos é gerada por permutações aleatórias uniformes dos nós.

3) *Seleção de Pais — Torneio*: Adota-se seleção por torneio de tamanho $k = 2$: sorteiam-se k indivíduos uniformemente e o de menor distância na rota é selecionado.

4) *Crossover SCX*: O operador *Sequential Constructive Crossover* (SCX) [9] é aplicado com probabilidade $p_c = 0,7$. Dado dois pais $\pi^{(1)}$ e $\pi^{(2)}$, o filho é construído sequencialmente a partir de uma cidade inicial. Em cada passo, considera-se a próxima cidade ainda não visitada sugerida por cada pai a partir da cidade atual. Entre as candidatas válidas, seleciona-se aquela associada ao menor custo de aresta no grafo do TSP. Caso ambas já tenham sido visitadas, escolhe-se a cidade não visitada de menor custo em relação à cidade atual. O processo continua até que todas as cidades sejam inseridas na solução.

5) *Mutação RSM*: A mutação *Reverse Sequence Mutation* (RSM) é aplicada com probabilidade de $p_m = 0,8$. No RMS, considera-se a estrutura do grafo TSP para selecionar duas arestas não subsequentes para inversão. Nesse processo as origens das arestas selecionadas são unidas, bem como os destinos, formando duas novas arestas. Em seguida, o trecho entre as arestas selecionadas é invertido, para manter a direção do ciclo, conforme a imagem.

Para esse processo, dada a ocorrência da mutação, foi estabelecida uma probabilidade de 0,7 da seleção dos pares de arestas seja aleatório, e 0,3 de chances de o operador iterar entre os pares de arestas para selecionar aquele que, ao ser invertido, reduz o tamanho total da rota. Esta estratégia foi adotada para permitir um certo grau de aleatoriedade, bem como de melhoria de soluções encontradas.




Figura 1. Operação de mutação RSM entre as arestas (3, 7) e (4, 8), adaptada de [10].

6) *Seleção de Sobreviventes — Elitismo Geracional*: A nova população é formada pelos $\lceil 0,02 \cdot N_p \rceil = 2$ melhores indivíduos da geração anterior (*elite*) mais os $N_p - 2$ melhores descendentes.

7) *Critério de parada*: O critério de parada adotado foi de número de gerações, e fixado em 2000.

8) *Hiperparâmetros*:

tableHiperparâmetros do AG para o TSP

Parâmetro	Símbolo	Valor
Tamanho da população	N_p	100
Probabilidade de cruzamento	p_c	0,70
Probabilidade de mutação	p_m	0,80
Probabilidade de mutação aleatória	p_{mrand}	0,70
Probabilidade de mutação com melhoria	p_{improv}	0,30
Tamanho do torneio	k	2
Elitismo	—	2%
Máx. de gerações	—	2000

IV. RESULTADOS E DISCUSSÃO

A. Função Rastrigin — DE

A Tabela III apresenta os resultados das 10 execuções independentes do DE.

Tabela III
RESULTADOS DO DE — FUNÇÃO RASTRIGIN ($n = 10$)

Exec.	Convergiu	Gerações	Melhor $f(x)$
1	Sim	581	0,000982
2	Sim	526	0,000823
3	Sim	451	0,000856
4	Sim	551	0,000775
5	Sim	625	0,000997
6	Sim	624	0,000980
7	Sim	494	0,000804
8	Sim	416	0,000879
9	Sim	483	0,000774
10	Sim	509	0,000960
Taxa de sucesso			100%
Melhor valor			0,000774
Média			0,000883

O DE convergiu em todas as 10 execuções, com média de gerações em torno de 526. A Fig. 2 ilustra a curva de convergência da melhor execução (menor número de gerações, execução 8): a função objetivo decai suavemente de valores próximos a 100 até abaixo de 10^{-3} , evidenciando a capacidade da estratégia *current-to-best* em combinar exploração e exploração. A atração intensa ao melhor indivíduo ($\lambda = 0,9$) acelera a convergência na fase final.




Figura 2. Convergência do DE para a função Rastrigin — melhor execução (Execução 8, 416 gerações).

B. Função Rastrigin — PSO

A Tabela IV apresenta os resultados das 10 execuções do PSO.

O PSO apresentou taxa de sucesso de 40% nas 10 execuções, refletindo maior sensibilidade ao mínimo local característico da função Rastrigin. Nas execuções em que não convergiu, os valores ficaram presos em múltiplos de $f = A \approx 0,995$, sugerindo estagnação em ótimos locais da estrutura cossenoidal da função. A Fig. 3 ilustra a melhor execução (execução 8): o PSO apresenta comportamento oscilatório mais intenso na fase inicial, com convergência mais lenta comparada ao DE.

Tabela IV
RESULTADOS DO PSO – FUNÇÃO RASTRIGIN ($n = 10$)

Exec.	Convergiu	Gerações	Melhor $f(x)$
1	Não	999	3,979836
2	Não	999	1,989918
3	Sim	846	0,000900
4	Não	999	1,989918
5	Sim	800	0,000677
6	Não	999	0,994959
7	Sim	681	0,000770
8	Sim	689	0,000611
9	Não	999	0,994959
10	Não	999	0,994959
Taxa de sucesso			40%
Melhor valor			0,000611
Média			1,094751




Figura 3. Convergência do PSO para a função Rastrigin – melhor execução (Execução 8, 689 gerações).

1) *Comparação DE vs. PSO*: O DE superou amplamente o PSO nesta configuração: taxa de sucesso 100% vs. 40%, e menor número médio de gerações para convergir. A variante *current-to-best* confere ao DE maior capacidade de escapar de ótimos locais, ao passo que o PSO gbest tende a convergir prematuramente em funções multimodais com muitos ótimos locais como a Rastrigin.

C. TSP att48 — AG

A Tabela V resume os resultados de 30 execuções independentes do AG na instância att48.

Tabela V
RESULTADOS DO AG – TSP ATT48

Parâmetro	Valor
Gerações por execução	2000
Melhor fitness ($1/d$)	$9,0 \times 10^{-5}$
Distância mínima encontrada	10628
Distância máxima encontrada	10711
Mediana de distâncias encontradas	10628
Ótimo conhecido	10628

Observou-se um importante papel do operador RSM permitindo mutações randômicas de inversão de subrotas para exploração do espaço de soluções, aliado a heurística de seleção de pares que melhoram a rota total para a convergência. Apenas a

heurística reforça comportamento de rápida convergência para mínimos locais, enquanto a seleção aleatória não se mostrou boa o suficiente para localizar o ótimo global.

As Fig. 4 5 apresentam respectivamente a melhor rota encontrada e a curva de convergência para as 30 execuções. Observa-se que o AG atingiu um platô de fitness $\approx 9,3 \times 10^{-5}$ já nas primeiras gerações, mantendo-se praticamente estável até a geração 1000. Esse comportamento indica convergência prematura da população: com $N_p = 50$ e $p_m = 0,5$, a diversidade genética esgota-se rapidamente, levando à estagnação em um ótimo local. A rota obtida ainda apresenta cruzamentos visíveis, evidenciando que há espaço para melhoria.




Figura 4. Melhor rota encontrada pelo AG.




Figura 5. *fitness* dos melhores indivíduos ao longo das 2000 gerações para cada uma das 30 execuções independentes do algoritmo.

Das 30 execuções, 25 convergiram para o valor máximo

de *fitness* (rota ótima conhecida). Observa-se na evolução do algoritmo a existência de longos platôs, que indicam a estagnação em ótimos locais, nos quais as operações de recombinação e mutação não tiveram facilidade para encontrar soluções melhores.

V. CONCLUSÃO

Este trabalho apresentou a aplicação de três algoritmos evolucionários a dois problemas de otimização. Para a função Rastrigin ($n = 10$), o DE na variante *current-to-best/1/bin* demonstrou desempenho superior ao PSO gbest, com taxa de sucesso de 100% frente a 40%, atingindo valores de $f(\mathbf{x}) < 10^{-3}$ em todas as execuções. A inércia adaptativa do PSO melhora sua exploração, mas a estrutura multimodal densa da Rastrigin favorece o mecanismo diferencial do DE.

Para o TSP att48, o AG com SCX e RSM atingiu um fitness mediano de $9,0 \times 10^{-5}$ e distância de 10628, de acordo com ótimo esperado. A mescla entre operações de mutação randômicas e orientadas a promoção de redução de da distância total se mostrou eficiente para balancear exploração do espaço das soluções e melhoria local das soluções.

Como trabalhos futuros, recomenda-se a aplicação de outros algoritmos evolucionários como o PSO e o DE para comparação de performance para o problema do TSP.

REFERÊNCIAS

- [1] A. E. Eiben e J. E. Smith, *Introduction to Evolutionary Computing*, 2^a ed. Springer, 2015.
- [2] R. Storn e K. Price, "Differential evolution – a simple and efficient heuristic for global optimization over continuous spaces," *Journal of Global Optimization*, vol. 11, n. 4, pp. 341–359, 1997.
- [3] J. Kennedy e R. Eberhart, "Particle swarm optimization," in *Proc. IEEE ICNN*, vol. 4, pp. 1942–1948, 1995.
- [4] D. E. Goldberg, *Genetic Algorithms in Search, Optimization and Machine Learning*. Addison-Wesley, 1989.
- [5] D. E. Goldberg e R. Lingle, "Alleles, loci, and the traveling salesman problem," in *Proc. ICGA*, pp. 154–159, 1985.
- [6] R. Matai, S. P. Singh e M. L. Mittal, *Traveling Salesman Problem: An Overview of Applications, Formulations, and Solution Approaches*. InTech, Croatia, 2010.
- [7] G. Reinelt, "TSPLIB – a traveling salesman problem library," *ORSA Journal on Computing*, vol. 3, n. 4, pp. 376–384, 1991.
- [8] G. A. Croes, "A method for solving traveling-salesman problems," *Operations Research*, vol. 6, n. 6, pp. 791–812, 1958.
- [9] Z. H. Ahmed, H. Haron e A. Al-Tameem, "Appropriate combination of crossover operator and mutation operator in genetic algorithms for the travelling salesman problem," *Computers, Materials and Continua*, vol. 79, n. 2, pp. 2399–2425, 2024.
- [10] C. Wang, R. Zhu, Y. Jiang, W. Liu, S.-W. Jeon, L. Sun e H. Wang, "A scheme library-based ant colony optimization with 2-opt local search for dynamic traveling salesman problem," *Computer Modeling in Engineering & Sciences*, vol. 135, pp. 1209–1228, 2022.